OPEN SOURCE, NOVEMBRE 2026

Insegnare a un piccolo modello OCR a leggere i documenti italiani

Dal modello di partenza a oggi, un passo alla volta, su un Mac con 16 GB di memoria.

1,2 GB

il modello, contro i 2,7 GB dell'originale

In locale

gira su Apple Silicon con MLX, e altrove con llama.cpp

Deciso prima

ogni test è scritto prima di farlo girare, le perdite accanto ai guadagni

Quattro passi

1. **Originale.** GLM-OCR di Z.ai, così come è stato pubblicato: un piccolo modello visione-linguaggio che trasforma l'immagine di una pagina in testo.

2. **Fine-tuning.** Un piccolo adattatore addestrato su 91 pagine italiane e inglesi che l'originale leggeva male, poi compresso a 8 bit: il 45% della dimensione.

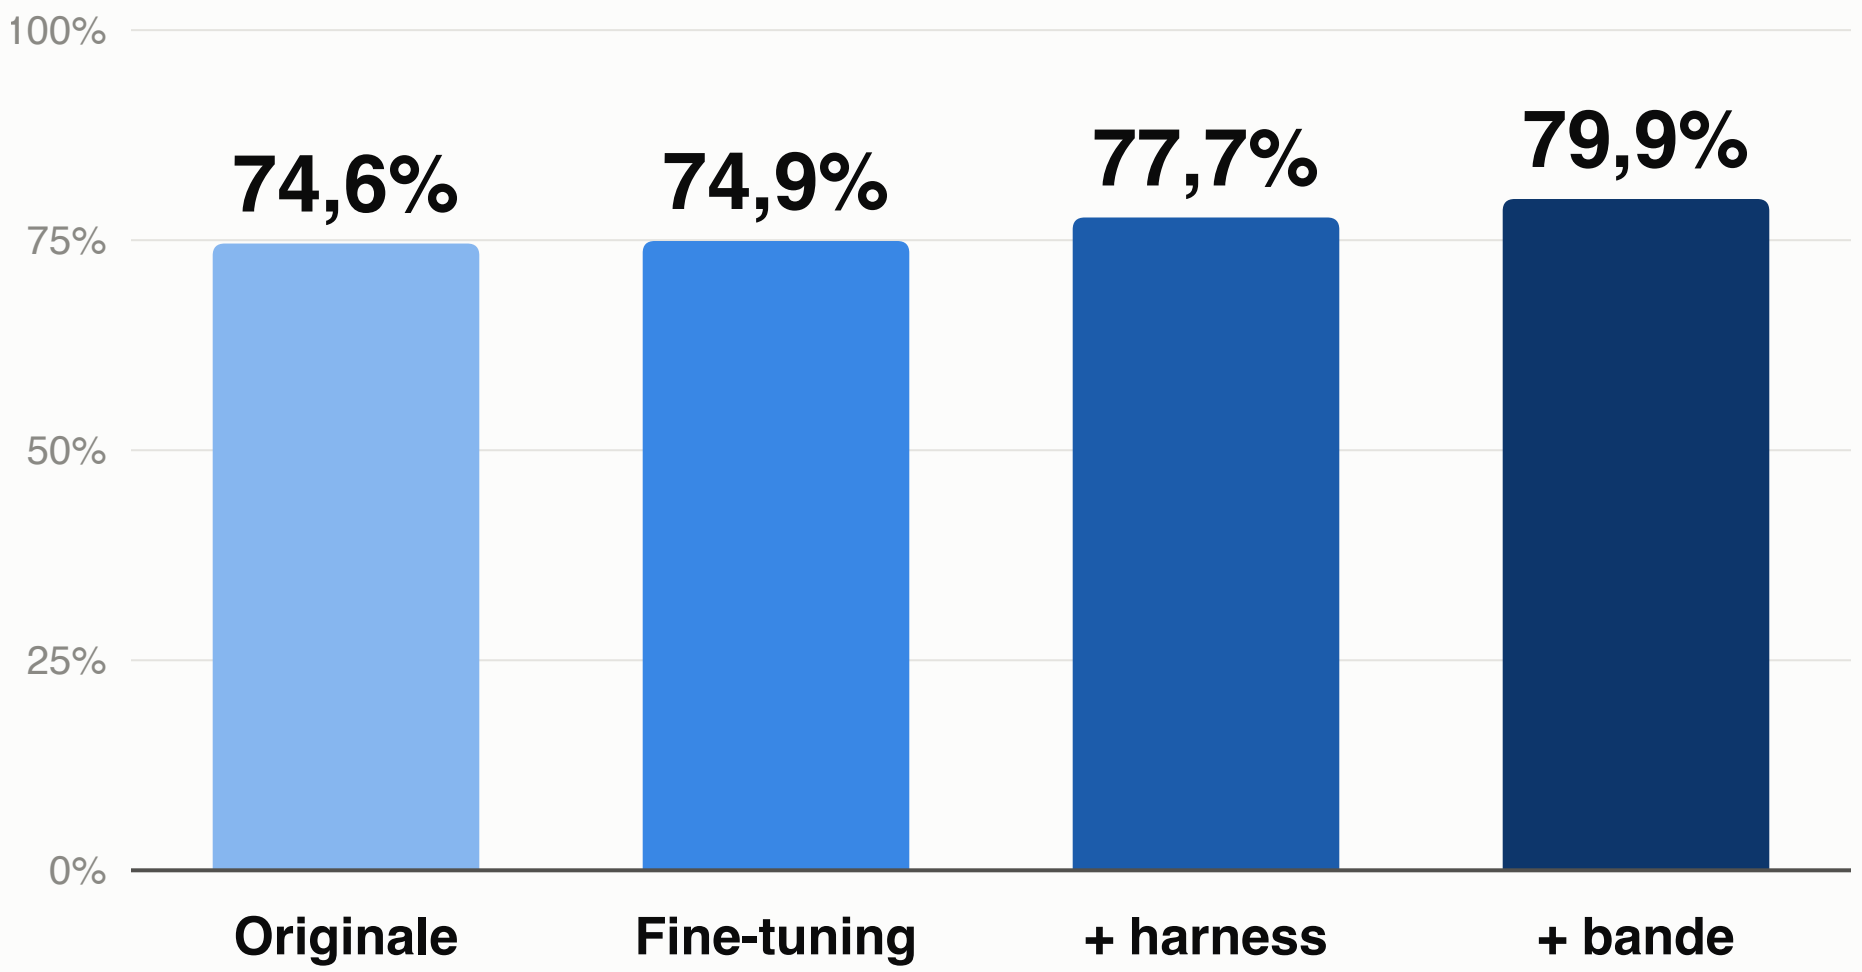
3. **+ harness.** Il programma che guida il modello. Lo ferma quando comincia a ripetersi e rilegge la pagina, e da un PDF legge il suo testo quando ci si può fidare.

4. **+ bande.** Gli ultimi due giorni, rilasciate con la v1.5.0. L'inizio e la fine di ogni pagina vengono riletti a parte, per recuperare intestazioni e righe di chiusura che la lettura intera perde. Un piccolo controllo dell'orientamento salta le pagine girate su un lato.

Il punteggio di ogni grafico: la quota di campi chiave letti esattamente (importi, date, codici fiscali, IBAN, campi dei moduli), oppure il punteggio del benchmark stesso.

Moduli italiani reali

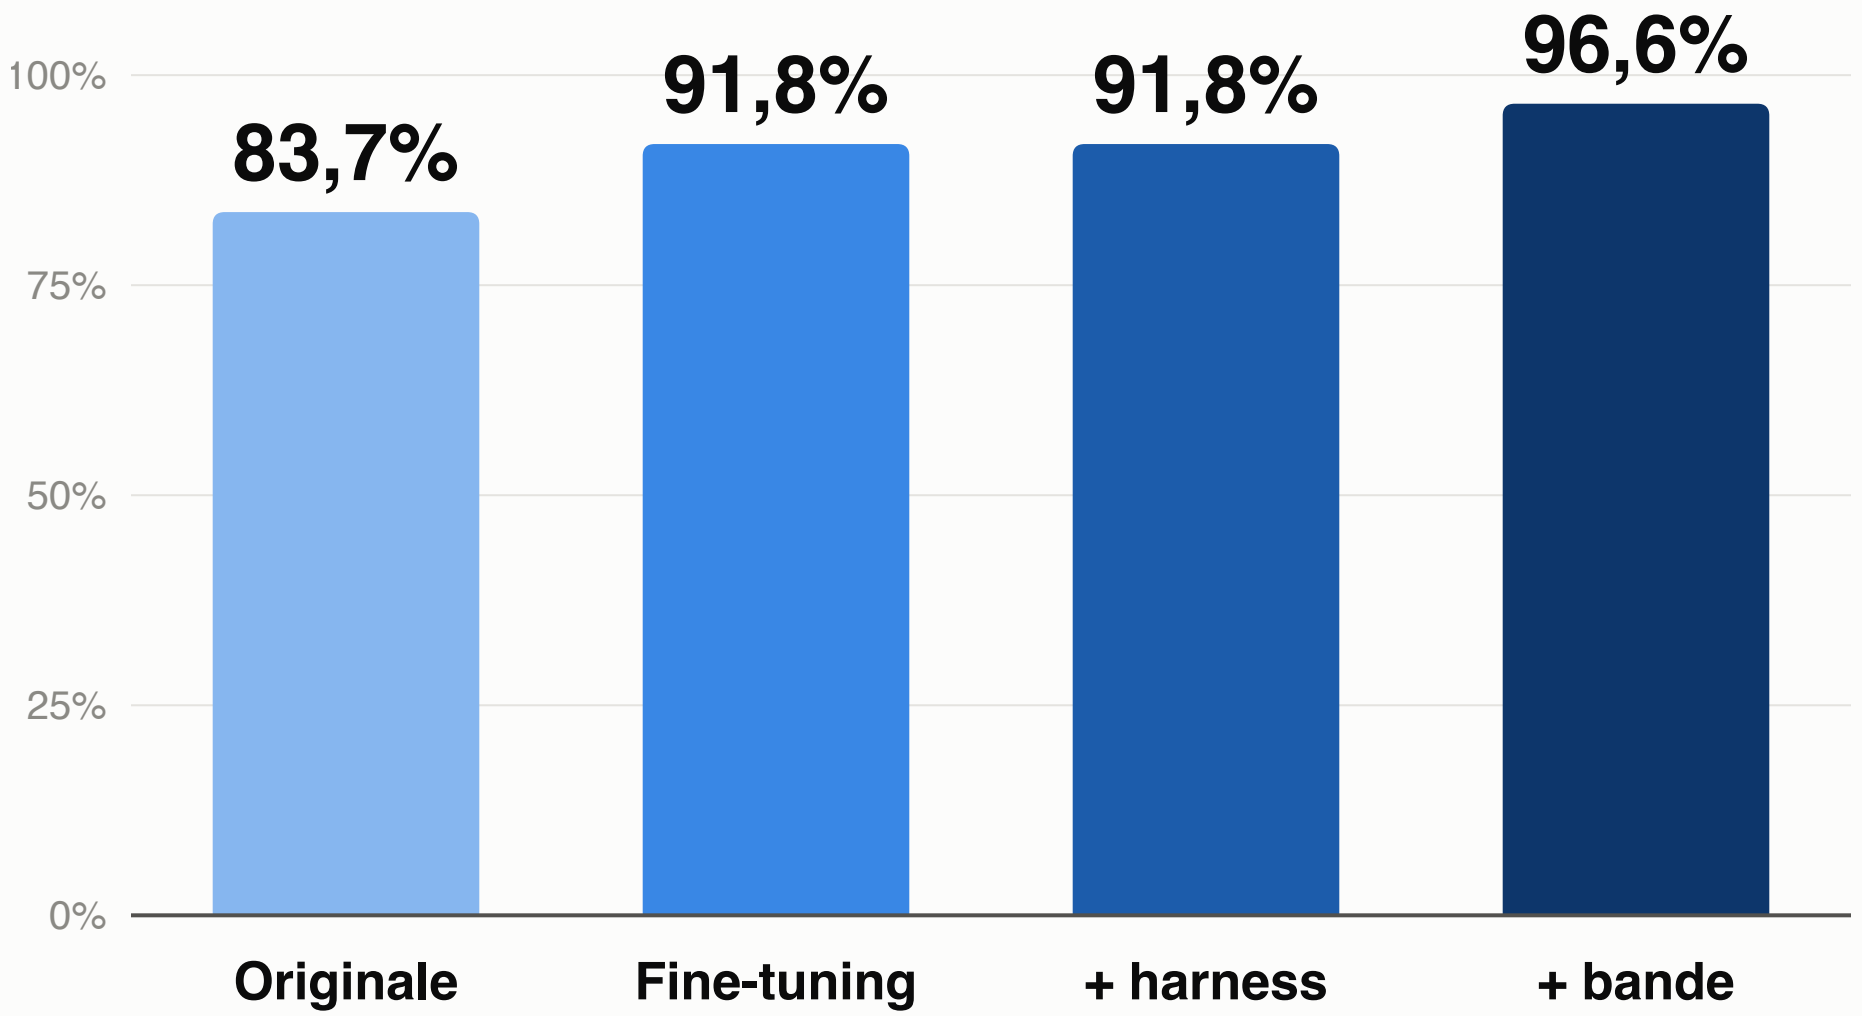
XFUND, 50 moduli scansionati, set di test



Campi mancati: **da 25,4% a 20,1%**. Qui il fine-tuning da solo era un pareggio; la differenza l'hanno fatta l'harness e le bande.

Pagine difficili

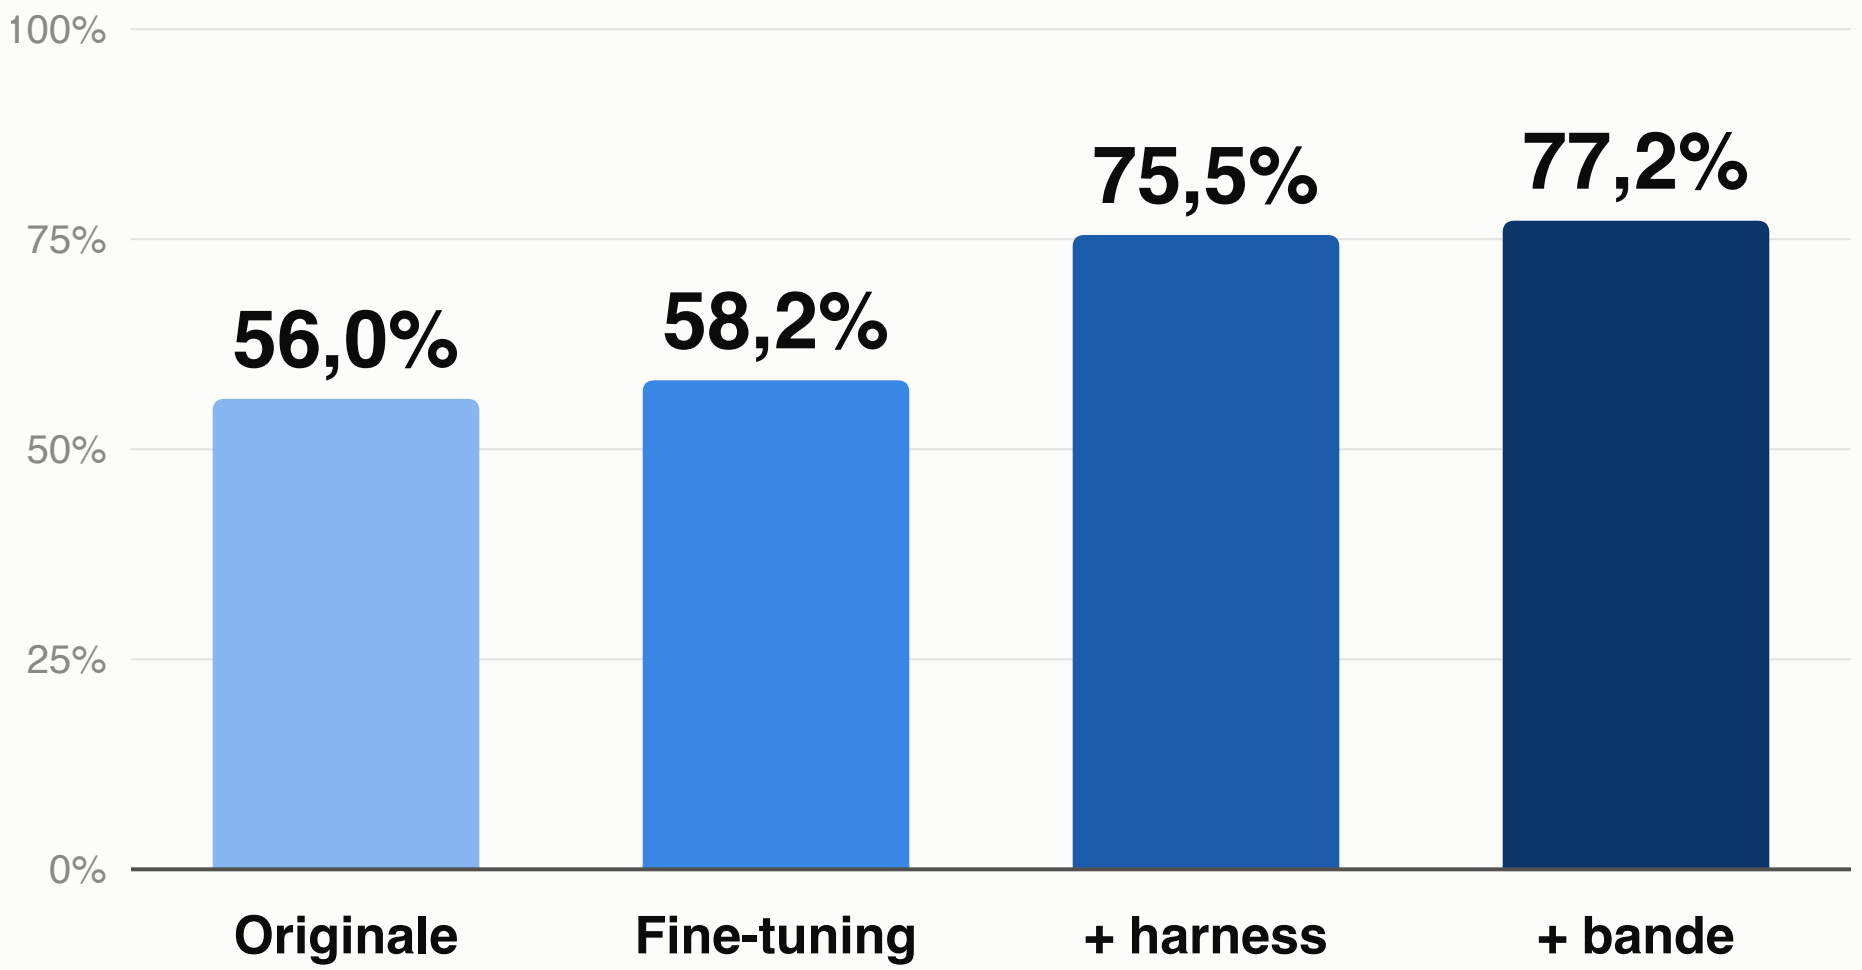
ocr-bench-v1, 50 pagine: foto da telefono, scansioni rovinate, timbri, in italiano e inglese, set di test



Campi mancati: **da 16,3% a 3,4%**, quasi cinque volte di meno. Il grosso l'ha fatto il fine-tuning; qui nessuna pagina va in loop, quindi l'harness non aveva niente da correggere. Nessuna pagina è peggiorata in nessun passo.

PDF reali

Omni Parse Bench di Datalab, 80 pagine di PDF reali, i test sul testo del benchmark stesso



Il salto grande è l'harness che legge il testo già contenuto nel PDF, quando supera quattro controlli: un'idea presa da Indra OCR di Datalab. Poi le bande migliorano le pagine lette dal modello, senza perderne nessuna.

Quanto costa, e cosa non fa

- **Tempo.** Le bande aggiungono dal 15 al 25% al tempo di una pagina. Su 200 lettere mai viste da nessun modello hanno portato i campi trovati da 92,4% a 96,1%, e le pagine con le righe di chiusura perse da 16 a 1.
- **Memoria.** 2,1 GB al picco, contro i 3,2 GB dell'originale.
- **Le pagine in cinese** lette intere vanno peggio che con l'originale. Le pagine girate di 90 gradi vanno ancora raddrizzate prima.
- **Come si misura.** Ogni test è deciso in un registro pubblico prima di farlo girare, con intervalli al 95% appaiati per pagina, e ogni numero è ricalcolato dagli output grezzi dalla suite di test.

github.com/fabriziosalmi/glm-ocr-ita

huggingface.co/fabriziosalmi/GLM-OCR-ita-mlx-8bit

Enjoy and contribute.